

DISEÑO DE UN MODELO PREDICTIVO CON REDES NEURONALES ARTIFICIALES PARA LA REOLOGÍA DE PULPAS TOMANDO DATOS CARACTERÍSTICOS DE SEDIMENTACIÓN

Eduardo E. Tapia¹

RESUMEN

La mayor parte de las industrias mineras de Chile con procesos metalúrgicos, tienen operaciones que utilizan cantidades profusas de agua, como es en el caso de la flotación, siendo el descarte de este proceso de casi un 95% de agua, por lo que la recuperación de agua es crucial. En este estudio enfocado a la reología se presentará una metodología de análisis y técnicas basadas para la predicción con redes neuronales. Se emplearon diversos factores que afectan e influyen a la reología de una muestra previamente sedimentada con floculante, buscando el mejor manejo y selección de datos de entrenamiento para una red neuronal que ayuden a la predicción de las variables de Yield Point Unshear, Yield Point Fully Shear, Viscosidad y Yield Stress con un error de un 10% a 20% respectivamente para la relación de los datos predichos y datos reales.

Palabras clave: Redes neuronales; Reología; Reómetro; Viscosidad; Yield Stress; Yield Point Unshear; Yield Point Fully Shear.

Introducción

Reología, la ciencia de la física que estudia la relación entre el esfuerzo y la deformación de la materia para su flujo, es una disciplina ingenieril establecida con aplicaciones en varios campos de la minería y metalurgia (Aguilar, Sàez, Lloréns, Soler, & Ortuño, 2002). El comportamiento del flujo impacta en la transferencia de masa y energía, por lo cual es base de análisis en las operaciones unitarias metalúrgicas de gran tonelaje y procesando bajo un flujo continuo tales como mezcla, transporte, bombeo, molienda, filtrado y espesamiento, estas operaciones son de plantas.

Los procesos que implican la separación gravitacional física líquidos-sólidos serían de sedimentación, espesamiento y engrosamiento. Como resultado, la reología se ha convertido en una parte importante de los programas de la minería para las pruebas metalúrgicas en proyectos de recuperación de agua en los espesadores específicamente (Méndez, 2016). El tipo de mineral y la variabilidad dentro del yacimiento hace que aumente la cantidad de datos reológicos necesarios para la caracterización adecuada del depósito y la posterior generación de criterios de diseño completos. Las necesidades de datos reológicos de las industrias mineras y metalúrgicas constarán de una evaluación de fluidez y la generación de criterios de diseño.

Los parámetros de interés que aparecen en los modelos reológicos son el Yield Point Unshear, Yield Point Fully Shear, Yield Stress y Viscosidad dependen de las propiedades y características del mineral (Gilberto & Perdomo, 2002). Resultando importante en la relación de la gravedad específica del mineral, su concentración de sólido, mineralogía, tipo y dosis floculantes, arcillas y el pH (Minería Chilena, 2020). Así caracterizando el mineral y utilizar ecuaciones constitutivas que relacionen los esfuerzos aplicados sobre la pulpa y las deformaciones que sufre, son medidas directamente con los equipos reológicos.

El método reológico es utilizado durante décadas por un reómetro, que es un dispositivo que puede ejercer una fuerza sobre un material y medir con alta precisión la respuesta de éste, por medio de cilindros coaxiales con velocidad angular (Torres García & Valencia, 2014). El

dispositivo utilizado es conocido como modelo Searle, el cual el cilindro exterior está fijo, mientras que el interno puede rotar con velocidad angular ejerciendo un torque en la pulpa contenida entre los dos (Anton Paar, 2014).

Las pulpas utilizadas son de principio plásticos Bingham, por ser de un tipo pastoso, que cuando se les someten a bajos esfuerzos se comportan como un sólido rígido pero que, pasando un cierto valor del esfuerzo τ_0 , se comportan como un fluido tipo Newton (Raimond & Carraher, 2002).

$$\tau = \tau_0 + \eta \left(\frac{du}{dy} \right) \quad (1)$$

Estos ensayos mayormente se realizan en temperatura ambiente con el reómetro VT550 y rotor MV-DIM a través del método CUP (Torres García & Valencia, 2014). En la **Figura 1** se realiza ejemplo de reología con una concentración en peso 41%, en un fluido del tipo Bingham (Raimond & Carraher, 2002), el Yield Stress τ_0 es de 1.816 [Pa] y la Viscosidad $[\eta]$ 0.01164 [Pa*s].

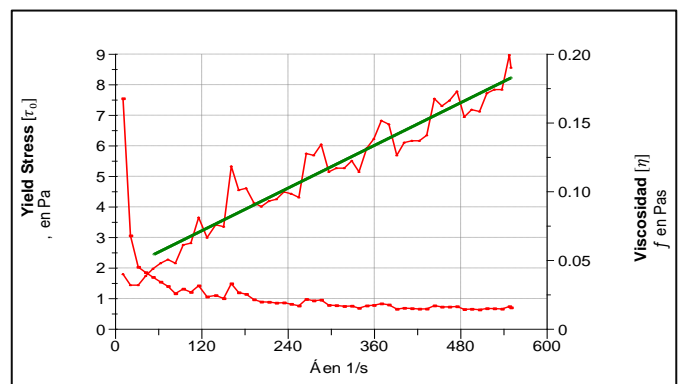


Figura 1: Medición de Yield stress y Viscosidad en un Reómetro (Tapia Hernández, 2020).

La mayor dificultad en el desarrollo matemático radica en encontrar una ecuación que represente la de Bingham y que además involucre las principales variables físicas, químicas y mecánicas que influyen el comportamiento de flujo de pulpa en los cilindros coaxiales. Esta situación resulta crítica para los procesos donde no se tiene información mineralógica y de arcillas (Klein & Hurlbut, 1997), por lo que se constata de datos sedimentarios para definir respectivamente la importancia de como el esfuerzo de influencia de Bingham en la concentración de partículas sedimentada influye tanto en la viscosidad como en el esfuerzo de fluencia de la pulpa, ya que, a medida que la concentración crece, la viscosidad y el esfuerzo de fluencia crece (Merrill Cifuentes, 2016). En la **Figura 2** se ilustran las empresas a un crecimiento del porcentaje de sólido para el Yield Stress.




Figura 2: Aumento de Yield stress al aumento del % de sólido (Tapia Hernández, 2020).

Hasta el momento no se ha desarrollado un modelo matemático o alguna nueva aproximación que sea capaz de representar el comportamiento reológico sin el reómetro en su totalidad. Dado que el proceso de reología está influenciado por una variedad de factores en desarrollar un modelo matemático para gobernar el proceso del reómetro, siendo complicado de desarrollar e implementar. En consecuencia, se han implementados con éxito modelos estadísticos, correlación y factores de importancia para la reología de muestras de mineral sedimentadas en un fluido, estos modelos se han utilizado tradicionalmente para la relación funcional entre las variables predictores y las variables de respuesta en lo que se utilizara una red neuronal artificial (RNA), constituyendo una alternativa para la predicción anticipada y rápida de pruebas de mineral sedimentadas en laboratorio para ser utilizadas para los procesos donde se pretende conocer o verificar la reología de estas.

Sedimentación estática

Debido a la gran variación que presentan las pulpas de minerales en términos de factores la estimación de los parámetros reológicos es incierta. Es posible reunir información de bases de datos de distintas empresas de Chile similares para estimar valores de dichos parámetros, pero ellos deben ser utilizados cuidadosamente dado que las características de las pulpas producidas dependerán en buena medida del mineral extraído según el plan minero de la empresa. En el análisis de datos hacia las empresas mineras se deberán identificar como PA, PB, PD, PE, PF, PG y PH debido a la confidencialidad de su identidad, estos datos son del estudio realizado con anterioridad en el análisis de espesadores de relave (Tapia Hernández, 2020).

Las empresas analizadas serán seleccionadas con restricciones generales en las bases de datos:

- Velocidad [m/h] de 0 a 15.
- % sólido final de 40 a 60%.
- Volumen Final [ml] 200 a 260.
- Área Unitaria [m²(24 h) / ton] de 0 a 005.
- Gravedad Específica de 0.6 a 3.14.
- Peso seco de 184g.
- Aumento de porcentaje de sólido 50 al 60[%]
- Tipo de floculante similares Tipo (1,3,4,5,6,7)
- Dosis de floculante 5 al 10 [g/t].
- El pH de la muestra está entre 7 y 9.

En este estudio, las pruebas de sedimentación tienen condiciones que constan con definir parámetros de granulometría, reactivo, peso(gr), pH y temperatura. Llevándose a cabo el análisis de 220 pruebas de sedimentación con floculante, temperatura ambiente y a un pH 7 a 10. Los datos obtenidos e interés de una prueba de sedimentación son la gravedad específica, velocidad, volumen final, porcentaje de sólido final, porcentaje de sólido inicial y área unitaria. Las pruebas no contienen aditivos del proceso metalúrgico de flotación, como es el caso de colectores y espumantes, siendo una muestra dirigida al análisis de espesadores de relave que específicamente se le agregara el reactivo floculante para la aglomeración de las partículas en un medio acuoso y en el caso que se necesite la desestabilización superficial de las partículas coloidales, se le agregara coagulantes del tipo cal o ácido sulfúrico, obteniendo la neutralización de sus cargas electroestáticas (Aguilar, Sáez, Llorénz, Soler, & Ortuño, 2002).

El análisis de la gravedad específica es factor en la sedimentación, ya que es la densidad de un material en relación con el agua. Dado que las rocas constan de varias fases distintas de mineral y no tienen una gravedad específica fija que se pueda dejar de lado. Este tipo de análisis se utilizará para la selección de los proyectos, comparando los datos en conjunto, dado que muchos datos tienen pH, porcentaje de sólido inicial y velocidad de sedimentación distintas.

El análisis del porcentaje de Sólido final y la velocidad en metros por horas de sedimentación muestra a cuanto velocidad termina de compactar y se obtiene un porcentaje de sólido final. En la **Tabla 1** se ilustra las estadísticas para seleccionar solo los datos agrupados entre el 25 al 75% de los datos por empresa.

Tabla 1: Estadística de todas las empresas para la Velocidad [m/h]

	PB	PA	PD	PE	PG	PF	PH
25%	2,92	12,54	11,91	4,74	4,42	5,62	9,96
50%	8,58	14,34	13,86	13,47	8,22	12,30	11,64
75%	13,02	27,96	14,70	27,99	11,04	25,08	21,90
Media	8,85	18,50	15,28	15,34	7,27	15,31	13,88

La diferencia del porcentaje de sólido final con el inicial es debido por la compactación con floculantes e hidratación de la muestra por las arcillas se ocasionándose una expansión que se obtiene un sólido distinto a la inicial. El porcentaje de sólido influye mucho en el comportamiento reológicos de la muestra al momento de sedimentar y formar la cama de sólidos, el porcentaje de sólido varía según la estadística en análisis de las muestras por empresa. En la **Tabla 2** se ilustra las estadísticas para seleccionar solo los datos agrupados entre el 25 al 75% de los datos por empresa.

Tabla 2: Estadística de todas las empresas para el % Sólido Final

	PB	PA	PD	PE	PG	PF	PH
25%	51,28	55,25	56,22	48,76	57,71	47,53	50,82
50%	54,97	57,86	59,28	53,89	62,32	53,52	52,93
75%	58,79	60,67	60,82	58,21	64,79	55,92	54,86
Media	55,11	57,99	58,57	53,69	59,84	51,98	52,67

El análisis del Área Unitaria es para ver a cuanto sería el flujo de alimentación al respectivo diseño del espesador. El área dependerá de la velocidad de sedimentación y la concentración de sólidos en la alimentación. El método más utilizado para el cálculo del Área Unitaria en este proyecto es con el método de Coe y Clevenger (Fuerstenau & Han, 2003), que se utiliza con la sedimentación de muestras con floculantes, con esto se realiza el diseño de espectadores. Esto da la relación a menor área unitaria, mayor % de sólido final. En la **Tabla 3** se ilustra las estadísticas para seleccionar solo los datos agrupados entre el 25 al 75% de los datos por empresa.

Tabla 3: Estadística las empresas para el Área unitaria [m²h/ton]

	PB	PA	PD	PE	PG	PF	PH
25%	51,28	55,25	56,22	48,76	57,71	47,53	50,82
50%	54,97	57,86	59,28	53,89	62,32	53,52	52,93
75%	58,79	60,67	60,82	58,21	64,79	55,92	54,86
Media	55,11	57,99	58,57	53,69	59,84	51,98	52,67

Reología de mineral

Las mediciones de reología se realizan con el reómetro, pero se debe utilizar diferentes copas con sensores. Se clasifican por dos tipos, para obtener los resultados de Yield Point Unshear y Full Shear se utiliza el método Vane que es el cambio de la deformación por unidad de tiempo. y por diferentes tipos de sólido se utiliza el método copa con la ecuación de Bingham, que se puede extrapolar en una línea de tendencia para generar ecuación lineal encontrando el Yield Stress que es la fuerza aplicada a un área de producto y la viscosidad es la oposición de un fluido al ser transportado o empujado (García Quesada, 2008).

Los resultados de reología que son la viscosidad y Yield Stress, se calculan por el sensor más apropiado para producir las variables de análisis a partir de una curva de flujo operando bajo esfuerzo controlado por el reómetro. El análisis realizado con el aumento de sólido es el principal objetivo para determinar la predicción de viscosidad y Yield Stress. La medición de los Yield Stress por empresas tienen mediciones en la misma muestra con distintos % de sólidos. El Yield Stress ocurre debido a que la muestra está en reposo y se genera el cizallamiento, provocando que las partículas inmersas en la muestra se alinean en dirección al flujo como es el caso de las cadenas de polímeros que se comienzan a alargar y los agregados o aglomeración de las partículas se procedan a romper. La viscosidad es una variable que se determina indirectamente por conversión de los valores de esfuerzo o torque medidos sobre la muestra, teniendo en cuenta la geometría del dispositivo de medición y es caracterizada por ser la resistencia al flujo en pascuales por segundos. Las estudianticas del Yield stress y la Viscosidad al aumento de sólido se ilustra en la **Tabla 4**.

El Yield Point Unshear [Pa] es para cuanto sólido necesita de fuerza para moverse el rotor en reposo o para ver la fuerza necesaria para cizallar el sólido sedimentado en el espesador, esto ayudaría a ver cuál es la fuerza en pascuales es necesaria hacer funcionar el espesador en estado de reposo. En la **Figura 3** se ilustra de cuanto esfuerzo necesita la muestra en cada empresa en estado de reposo.




Figura 3: Yield Point Unshear [Pa].

Tabla 4: Estadística de las empresas por porcentaje de sólido creciente en Viscosidad [Pas] y Yield Stress [Pa].

	SÓLIDO	VISCOSIDAD [Pas]							YIELD STRESS [Pa]						
		PA	PB	PD	PE	PF	PG	PH	PA	PB	PD	PE	PF	PG	PH
MÁXIMA	1	0,16	0,14	0,03	1,00	0,09	0,03	0,98	62,84	15,78	25,59	27,72	62,86	26,66	18,22
	2	0,28	0,15	0,07	0,96	0,17	0,06	0,88	70,13	32,33	66,91	53,11	125,4	73,68	71,46
	3	0,82	0,21	0,14	1,00	0,35	0,20	0,99	97,59	56,7	87,69	165	145	112,3	293,5
MÍNIMA	1	0,01	0,01	0,01	0,11	0,01	0,00	0,10	0,01	0,01	0,96	0,29	0,13	0,28	0,15
	2	0,01	0,01	0,01	0,10	0,01	0,01	0,11	0,15	0,65	2,63	0,59	1,73	1,05	0,58
	3	0,01	0,01	0,01	0,11	0,01	0,02	0,11	1,33	2,2	6,1	0,86	2,12	4,34	1,51
MEDIA	1	0,03	0,02	0,02	0,25	0,02	0,02	0,23	6,93	3,72	8,67	3,92	7,15	4,01	3,25
	2	0,05	0,03	0,02	0,28	0,03	0,03	0,40	13,07	8,32	17,93	7,09	13,58	11,54	10,65
	3	0,09	0,04	0,04	0,34	0,05	0,05	0,42	23,78	16,33	30,03	14,24	24,75	28,54	49,31

El análisis se realizará con los datos obtenidos de las muestras en el proceso Reología. Luego de la sedimentación estática obteniéndose el porcentaje de sólido final, se procede a la reología. Se comienza con la medición del Yield Point Unshear el cual la muestra se encuentra en reposo y estática. También se utiliza estos datos para obtener un análisis de la sedimentación por gravedad sin rotor y con solo la bomba de traspaso. Las estadísticas del Yield Point Unshear por empresa se ilustra en la **Tabla 5**.

Tabla 5: Estadística Yield Point Unshear [Pa].

	PB	PA	PD	PE	PG	PF	PH
25%	60,95	124,63	78,40	97,88	27,26	13,54	102,30
50%	87,42	182,05	95,60	167,80	95,94	29,89	122,60
75%	121,33	242,53	136,20	223,83	196,78	59,22	151,45
Media	110,40	201,71	107,88	166,47	138,11	44,20	124,74

El análisis del Yield Point Fully Shear [Pa] es a cuenta fuerza que realiza el rotor en la muestra cizallada y s cuenta fuerza constante que realiza el roto del espesador. También se utiliza estos datos para obtener la sedimentación por movimiento del rotor. En la **Figura 4** se ilustra de cuanto esfuerzo necesita la muestra en cada empresa en estado de reposo.




Figura 4: Yield Point Fully Shear [Pa].

Luego del Yield Point Unshear se cizalla agitando la muestra para realizar el Yield Point Fully Shear. Con esto se tienen menos esfuerzos al cizallar la muestra, porque tiene la compactación menos rígida por el reposo que dejó el sólido final. Las estadísticas del Yield Point Unshear por empresa se ilustra en la **Tabla 6**.

Tabla 6: Estadística Yield Point Fully Shear [Pa].

	PB	PA	PD	PE	PG	PF	PH
25%	3,96	9,26	7,12	9,45	4,17	5,08	8,03
50%	5,08	12,96	9,59	16,75	6,19	9,02	11,10
75%	7,33	16,87	12,97	25,15	7,92	17,48	13,72
Media	6,11	14,25	10,50	18,07	6,63	12,60	12,17

Redes Neuronales Artificiales

El desarrollo de la inteligencia artificial es dado a la pregunta de la funcionalidad del cerebro y que se han dado mucho de los conceptos más importantes. Uno de los conceptos es el paradigma de aprendizaje que se refiere a los mecanismos que permiten que podamos procesar toda la información nueva que percibimos para transformar en conociendo. Según el paradigma de aprendizaje se usará en este estudio es el aprendizaje supervisado, que es un aprendizaje que se basa en descubrir la relación existente entre unas variables de entrada y unas variables de salida, eso quiere decir que aprenda y modifique sus parámetros de enlaces y errores por neuronas por si sola (Flórez López & Fernandez, 2008).

Una neurona es la unidad básica de procesamiento de unas redes neuronales y permiten desarrollar una estrategia de simulación directa sin tener a disposición un modelo matemático que se asume de bastante complejidad. Este aprendizaje surge de enseñarles a los algoritmos para obtener el resultado que se quiere generar para un determinado valor tras mostrar muchos ejemplos (de la Fuente Aparicio & Calong, 1999). Si se dan las condiciones el algoritmo será capaz de dar un resultado correcto incluso con un valor que no ha visto antes.

Entrenamiento

El entrenamiento de la red neuronal artificial es el proceso de aprendizaje, el cual se lleva a cabo mediante el procesamiento repetido de ejemplos validados en el mismo entrenamiento con una base de datos contundente. Dándole la capacidad de la red de aprender y memorizar grandes cantidades de información sin una relación aparente. Adicionalmente, el algoritmo es capaz de hacer predicciones a partir de los datos de la base de datos con los que ha sido entrenada la misma red neuronal artificial (Jones, 2019). Para determinar la arquitectura de la red neuronal no es determinada por métodos matemáticos, sino por medio pruebas y errores determinan cuál es la arquitectura más adecuada. Se compone una red neuronal artificial de las capas de entrada, otra capa de salida y un determinado número de capas ocultas encargadas del proceso interno de la red neurona.

La topología Capas de entrada-ocultas-salida de la red neuronal para la predicción del Yield Stress serán de 6-13-3 para la predicción de los tres tipos de sólidos 50,55 y 60 porcientos. La predicción de la Viscosidad será de 6-12-3 para la predicción de los tres tipos de sólidos 50,55 y 60 porcientos. Para la última predicción de la red neuronal será de una red neuronal más contundente, ya que por medio de pruebas y errores se pudo optar a la arquitectura de 6-22-10-7-2-2 a la predicción del Yield Point Unshear y Fully Shear en la misma red neuronal. Los datos de la red neuronal se ilustran en la **Tabla 7**.

Los procesamientos internos de las capas ocultas de las redes neuronales artificiales se componen de algoritmos que representan unidades simples de cómputo, interconectadas en una topología definida por las pruebas realizadas de validación, dando lugar a procesos de aprendizaje continuo y con síntesis de información. Sus salidas tienen las ventajas de no estar sujetas a un modelo matemático específico, son tolerantes a fallas localizadas de los datos de entrada y no necesitan de condiciones externas a los datos mismos. A menos que sea por la normalización y jerarquización.

El entrenamiento de la red neuronal será con el método de Feed Forward Backpropagation que es capaz de aproximar a cualquier función no convexa (Annema, 1995), generando una solución analítica con un determinado grado de precisión. Siendo una propagación automática hacia adelante, para luego validar el resultado predicho, el cual se propaga hacia atrás como una cadena de responsabilidades en toda la red, capa por capa. Esto es dado por que las capas anteriores dependen de las capas posteriores y con eso poder encontrar a la neurona de forma recursiva que tuvo la culpa por el error y penalizarla (Jayne, Yue, & Iliadis, 2012).

Para la utilización de método Feed Forward Backpropagation se utiliza la ecuación Levenberg Marquardt que actualizando los pesos y parámetros de las neuronas (Kumar Shukla, 2010). Este algoritmo es rápido en el entrenamiento de las redes neuronales, pero se deben tener los datos normalizados y estandarizados. En el caso de que no lo estén solo predecirá datos que se usaron para entrenar la red neuronal artificial. Siendo capaces de desarrollar relaciones funcionales entre datos de manera autónoma y proveer una herramienta funcional de precisión en planos de interpolación no lineal y multidimensional, se ha empleado a las redes neuronales artificiales principalmente en la resolución de problemas que involucran tareas de predicción e identificación de patrones automáticamente.

Una vez modificado los parámetros automáticamente se volverá a generar el mismo proceso de validación hasta que el error vaya disminuyendo para obtener un error mínimo en la predicción de la red neuronal se utilizará el método de descenso del gradiente (Anderson, 1997), que es el vector que contiene las pendientes de cada dimensión y se usa por ser un algoritmo para funciones no convexas, los cuales no tienen un solo valor mínimo global. Los mínimos se encuentran con la derivada indica la pendiente, el cual se puede medir la inclinación de cada punto de la función no convexa. La deriva se iguala a cero para encontrar donde es nula, derivando múltiples ecuaciones dado que las funciones no convexas tienen múltiples números mínimos.

Para acelerar la convergencia del error medio al cuadrado, se usa la función de activación de Hyperbolic tangent sigmoid y la Pure linear (Anderson, 1997). Las cuales en simples palabras son las encargadas de distorsionar el plano como el de la figura para encontrar el resultado óptimo con el descenso del gradiente. Las funciones de transferencia ayudan al momento del entrenamiento, ya que las sumas de todas las funciones generan el plano no convexo, ayudando al descenso del gradiente a converger más rápida (Pérez López & Santín Gonzáles, 2007)

Tabla 7: Capas de red neuronal para la arquitectura y el entrenamiento.

	RANGO	VARIABLE	INDICADOR
ENTRADA	0 – 15	Velocidad	[m/h]
	0 – 005	Área Unitaria	[m2h(24hrs) /ton]
	0.6 - 3.14	Gravedad Específica	[Gs]
	40 – 60	%Sólido Final	[%]
	200 – 260	Volumen Final [ml]	[ml]
	184g (seco)	%Sólido Inicial	[%]
SALIDA	RNA 1	Yield Stress	[Pa]
	RNA 2	Viscosidad	[Pa*s]
SALIDA	RNA 3	Yield Point Fully Shear	[Pa]
		Yield Point Unshear	[Pa]

Resultados RNA

La red neuronal constara de variables de entrada, capas ocultas y salida. Las seis variables de entrada serán de Velocidad [m/h], Área Unitaria [m²h(24hrs) / ton], Gravedad Específica [Gs], %Sólido Final [%], Volumen Final [ml] y %Sólido Inicial [%]. Estas seis variables de entradas serán para todas las redes neuronales artificiales que se mostraran a continuación.

La predicción del Yield Stress se probó la red neuronal con un numero de 30 muestras externas a la base de datos, estas pruebas tienen los datos de entrada de sedimentación para validar la precisión. Para esta red neuronal artificial tendrá dos capas ocultas la red neuronal con la función de activación será Hyperbolic tangent sigmoid, la capa oculta tendrá 13 neuronas y la capa de salida tendrá 3 neuronas. La salida será el Yield Stress a tres tipos de sólido creciente de 50, 55 y 60 porcientos ilustrada la arquitectura en la **Figura 5**. Los resultados de

la red neuronal artificial se pueden visualizar en la **Figura 6**, la cual cuenta con una predicción promedio de un **82,1%** de precisión, siendo la relación de los datos de predicción de la red neuronal artificial y los datos que se realizaron con el respectivo reómetro.




Figura 5: Arquitectura de la red neuronal para la predicción del Yield Stress para cada sólido.




Figura 6: Los resultados de Yield Stress para la predicción en la red neuronal para cada sólido

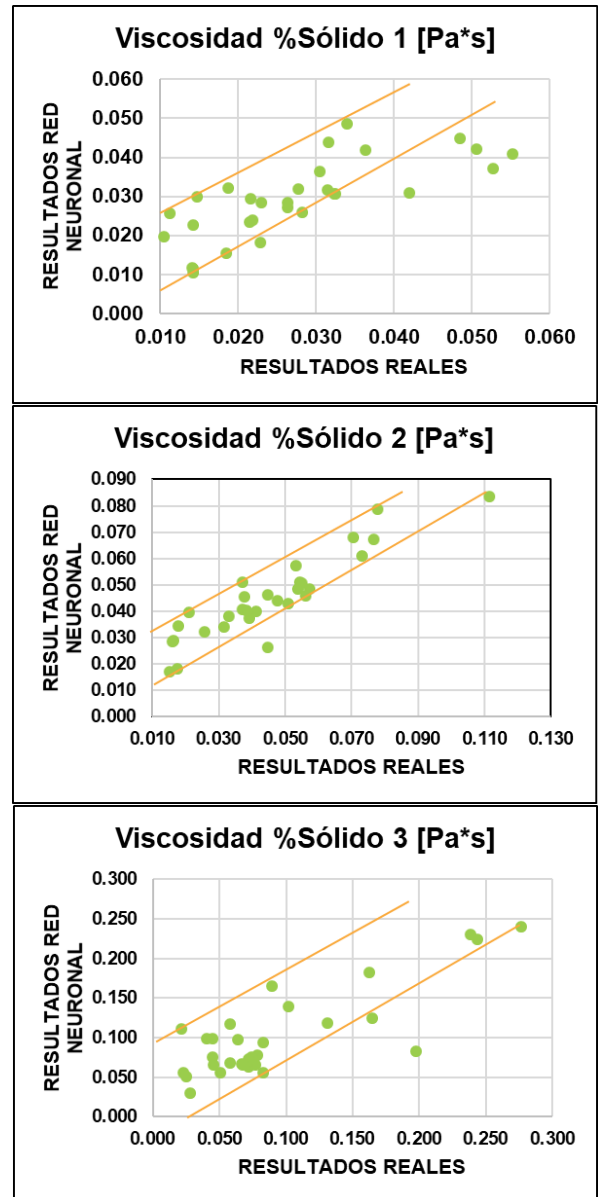


Figura 7: Los resultados de la Viscosidad para la predicción en la red neuronal para cada sólido

La predicción de la Viscosidad se probó la red neuronal con un numero de 30 muestras al igual que el Yield Stress, siendo externas a la base de datos. Para esta red neuronal artificial tendrá dos capas ocultas de procesamiento, contando con la función de activación Hyperbolic tangent sigmoid, la capa oculta uno tendrá una menos que la de Yield Stress contando con 12 neuronas y la capa de salida tendrá 3 neuronas de resultado. La salida será la Viscosidad a tres tipos de sólido creciente de 50, 55 y 60 porcientos ilustrada la arquitectura en la **Figura 8**. Los resultados se pueden visualizar en la **Figura 7**, la cual cuenta con una predicción promedio de un **80,7%** de precisión, siendo la relación de los datos de predicción de la red neuronal artificial y los datos que se realizaron con el respectivo reómetro.




Figura 8: Arquitectura de la red neuronal para la predicción de la Viscosidad para cada sólido.

Para la última predicción del Yield Point Unshear y Yield Point Fully Shear se eligió la arquitectura de la red neuronal artificial que constara de variables de entrada, capas ocultas y salida, pero con más capas. Las seis variables de entrada serán las mismas, siendo la Velocidad [m/h], Área Unitaria [m2h(24hrs) / ton], Gravedad Específica [Gs], %Sólido Final [%], Volumen Final [ml] y %Sólido Inicial [%]. Para la arquitectura de la red neuronal se tendrá tres capas ocultas la red neuronal con la función de activación Hyperbolic tangent sigmoid y la última para una mejor convergencia en el resultado será la de Pure lineal.

La capa uno tendrá 22 neuronas, la capa dos tendrá 10 neuronas, la capa tres tendrá 7 neuronas y la capa cuatro tendrá 2 neuronas para la salida. La capa de salida será el resultado Yield Point Fully Shear y Yield Point Unshear ilustrada la arquitectura en la Figura 8.




Figura 8: Arquitectura de la red neuronal para la predicción de la Viscosidad para cada sólido.

Los resultados de predicción que tienen las mismas entradas para las dos salidas de reología, Yield Point Unshear y Yield Point Fully Shear. La predicción del Yield Point Unshear y Yield Point Fully Shear se probó la red neuronal artificial con un numero de 4 muestras externas a la base de datos, estas pruebas tienen los datos de entrada de sedimentación para validar la precisión.

Para el resultado de la primera salida se tiene el Yield Point Unshear que tienen una predicción de las cuatro muestras que fueron relacionadas con el resultado real, desarrollada en el reómetro. Se ilustra en la relación y diferencia que tienen los datos reales con los predichos en la **Figura 8**.




Figura 8: Resultados del Yield Point Unshear de la salida 1 de la red neuronal.

La precisión de la red neuronal artificial de la salida 1 es de un **75,8%** en la predicción del Yield Point Unshear, si bien este nivel de predicción se asemeja como un valor bastante de sesgo, cabe analizar que los datos se encuentran en una relación aparente y un comportamiento similar ilustrando los resultados en la **Tabla 8**.

Tabla 8: Error medio al cuadrado (MSE) del Fully Shear y Unshear por cada neurona.

Prueba	1	2	3	4
RNA	0,118	0,202	0,134	0,070
REAL	0,127	0,253	0,102	0,038

Para el resultado de la segunda salida se tiene el Yield Point Fully Shear que tienen una predicción de las cuatro muestras que fueron relacionadas con el resultado real, desarrollada en el reómetro. Se ilustra en la relación y diferencia que tienen los datos reales con los predichos en la **Figura 9**.




Figura 9: Resultados del Yield Point Fully Shear de la salida 2 de la red neuronal.

La precisión de la red neuronal artificial de la salida 1 es de un **94,1%** en la predicción del Yield Point Unshear, confirma este resultado la predicción insesgada, siendo un resultado favorable al momento de predecir con variables de sedimentación en la capa de entrada y obtener datos reológicos en la capa salida. Ilustrando los resultados en la **Tabla 9**.

Tabla 9: Error medio al cuadrado (MSE) del Fully Shear y Unshear por cada neurona.

Prueba	1	2	3	4
RNA	0,2873	0,3121	0,3863	0,1937
REAL	0,293	0,325	0,320	0,195

Conclusión

Se analizaron los datos para su selección y se pudo comparar de una manera más insesgada los resultados obtenidos en la propuesta de predicción, como también fue posible identificar una serie de comparaciones de la reología que se ven en diversas plantas metalúrgicas de las mineras analizadas, debido principalmente al tipo de muestra que se presentan en cada empresa minera, con la subestimación o cómo afrontar los esfuerzos de influencia y viscosidad que terminan por dificultar la capacidad de tratamiento de mineral al imponer una concentración de sólidos en las pulpas de relave a tratar. En la selección de empresas se optó por tomar solo las empresas que tenían todos los datos necesarios para ser comparadas y los filtros desarrollados en las variables de análisis, ayudaron significativamente en la visualización y comportamiento para una posterior comparación y análisis de todos los datos de reología en empresas.

El análisis de las empresas con la herramienta se logra establecer una amplia base de datos para la comprensión de los fenómenos físicos reológicos asociados a cada minera con sus respectivas pruebas en el laboratorio. Se identificaron las principales variables que tenían incidencia e importancia para el esfuerzo de Yield Point Unshear, Yield Point Fully Shear, Yield Stress y la Viscosidad.

Las arquitecturas y algoritmos utilizados en la red presentaron un modelo de regresión lineal con un ajuste de $R^2 > 0.9$ y un error de Datos Reales/Predichos con un [95-70]% en más de una empresa analizadas en las pruebas de reología Yield Point Unshear y Fully Shear. Siendo considerable el nivel de exactitud de predicción en la red neuronal porque las pruebas de laboratorio que tienen un nivel de error ya estandarizados en las pruebas metalúrgicas de laboratorio en las tomas de muestras, siendo una predicción con el menor sesgo o una predicción que tiene un comportamiento similar al real.

Para los resultados de Yield Stress o Viscosidad se creó una red neuronal para predecir el aumento de los tres tipos de sólido por muestra, obteniendo un resultado favorable de datos predichos con un sesgo de error exitoso en los datos de menor valor y aceptable para los de mayor valor porque al estandarizarlos se acercan demasiado al 1 dado que se dividió al número máximo de los datos de esa variable. Los gráficos de las dos empresas seleccionadas por tener parámetros y clasificaciones de laboratorio similares se analizan que los resultados de la red neuronal de Yield Stress o Viscosidad comparados con reales tienen una tendencia lineal exitosa.

Bibliografía

- Aguilar, M. I., Sàez, J., Lloréns, M., Soler, A., & Ortuño, J. F. (2002). *Tratamiento físico-químico de aguas residuales: coagulación-floculación*. España: Universidad de Murcia.
- Aguilar, M. I., Sàez, J., Lloréns, M., Soler, A., & Ortuño, J. F. (2002). *Tratamiento físico-químico de aguas residuales: coagulación-floculación*. España: Universidad de Murcia.
- Anderson, J. A. (1997). *An Introduction to Neural Networks*. London: Massachusetts institute of technology.

- Annema, J. (1995). *Feed-Forward Neural Networks: Vector Decomposition Analysis, Modelling and Analog Implementation*. New York: Kluwer Academic Publishers.
- Anton Paar. (2014). *Rheómetro Rotacional para Control de Calidad*. Anton Paar, 6.
- de la Fuente Aparicio, M. J., & Calong, T. (1999). *Aplicaciones de las redes de neuronas en supervisión, diagnóstico y control de procesos*. Caracas: Universidad de Simón Bolívar.
- Flórez López, R., & Fernandez, J. M. (2008). *Las Redes Neuronales Artificiales*. España: netbiblo.
- Fuerstenau, M. C., & Han, K. N. (2003). *Principles of Mineral Processing*. Colorado: Society for mining metallurgy and exploration inc.
- García Quesada, J. C. (2008). *Técnicas reométricas*. Alicante: Universidad de Alicante. Departamento de Ingeniería Química.
- Gilberto, A., & Perdomo, M. (2002). *Plástico y medio ambiente. Iberoamericana Polímeros*, 55-77.
- Jayne, C., Yue, S., & Iliadis, L. S. (2012). *Engineering Applications of Neural Networks*. London: Springer.
- Jones, H. (2019). *Las redes neuronales*. España: Independently Published.
- Klein, C., & Hurlbut, C. S. (1997). *Manual de mineralogía*. España: Reverté.
- Kumar Shukla, P. (2010). *Levenberg-Marquardt Algorithms for Nonlinear Equations, Multi-objective Optimization, and Complementarity Problems*. Alemania : Shaker Verlag GmbH.
- Méndez, R. (10 de 2016). *Floculantes modificadores reológicos. Minería Chilena*, 425, 49.
- Merrill Cifuentes, J. N. (2016). *Memoria de un estudio del efecto de la composición mineralógica en la reología de pulpas basado en técnicas de caracterización avanzada*. Santiago: Universidad de Chile.
- Minería Chilena. (24 de 06 de 2020). *Minería Chilena*. Recuperado el 9 de 6 de 2009, de La importancia del análisis reológico: <https://www.mch.cl/reportajes/la-importancia-del-analisis-reologico/#>
- Pérez López, C., & Santín Gonzáles, D. (2007). *Minería de datos. Técnicas y herramientas: técnicas y herramientas*. Madrid: Clara Mª. de la Fuente Rojo.
- Raimond, B. S., & Carraher, J. E. (2002). *Introducción a la química de los polímeros*. España: Reverté, S.A.
- Tapia Hernández, E. E. (2020). *Memoria de un estudio de las reologías históricas en mineras de Chile para el análisis de espesadores de relave mediante una herramienta computacional*. Santiago: Universidad Central de Chile.
- Torres García, D., & Valencia, D. (2014). *Reología de Pastas y Relaves. Diplomatura de especialización ingeniería de Piping* (págs. 1-41). Inglaterra: Polymers and Polymer Composites.